

プレゼミ 第 3 回 予習資料

「平均的な日本企業」とはどんな企業か —— R でデータを分析する

松浦 総一（経営学部）

i この資料の使い方（目安 40 分）

この資料は、第 3 回の授業に向けた**事前学習資料**です。**2 部構成**になっています。

順番	やること	目安
1	第 1 部 （この資料の §1～§2）を読む	5 分
2	予想フォーム B に送信する （moodle+R/← ここで一度資料を閉じる）	3 分
3	第 2 部 （§3～§5）を読む	10 分
4	課題 C ：配布データを R で読み込み、平均・中央値を計算して提出	15 分
5	課題 D ：次回の「環境構築大会」に向けて PC の空き容量を確認	5 分

締切はどちらも**授業前日の 23:59** です。

1. 第 1 部：まず、予想してください

1.1. 前回の振り返り —— 指標の裏側を見抜く

第 2 回では、「反証可能性」と「ROE のデュポン分解」を学びました。

- 「ROE が高い＝優れた企業」という常識を疑い、デュポン分解によって「**借金（財務レバレッジ）で無理やり ROE を釣り上げていないか**」を確かめる視点を手に入れました。
- 表面的な数字を鵜呑みにせず、**データの構造を疑うこと**こそが実証分析の第一歩です。

第 3 回では、もっと身近で、しかし誰もが日常的に騙されている「**平均**」という言葉の罠に切り込みます。

1.2. 予想してください（3 分・ここで一度閉じる）

ニュースでよく「上場企業の平均給与は〇〇万円」「日本企業の平均売上高は〇〇億円」という報道を目にします。

では、実際に日本の上場企業の**売上高**を集計したとき、「**平均値**」と「**中央値**」はどのような関係になると思いますか？

💡 言葉の定義の確認

- **平均値 (Mean)** : 全員の売上高を足し算して、会社数で割った値。
- **中央値 (Median)** : 会社を売上高の小さい順から大きい順に並べたとき、**ちょうど真ん中 (ど真ん中)** に位置する会社の売上高。

! 予想フォームへ (ここから先を読む前に!)

Q. 上場企業の売上高について、「平均値」と「中央値」はどちらが大きいですか？ また、どのくらい差があると思いますか？

- ① 「平均値」のほうがはるかに大きい (中央値の **2 倍以上**)
- ② 「平均値」のほうが少し大きい (中央値の **1.1 倍~2 倍未満**)
- ③ 「平均値」と「中央値」は**ほぼ同じ** (左右対称の分布)
- ④ 「中央値」のほうが大きい

理由も 1 行書いて、フォームから送信してください。

提出先 : moodle+R の「第 3 回 予想シート B」

- 当たり外れは**成績に一切使いません**。提出したかどうかだけを見ます。
- **先を読んでから答えると、損をします**。この予想の価値は「習う前のあなたの直感」が記録に残ることにあります。授業は、みなさんの予想の集計を映すところから始まります。

2. 第 2 部 : 予想を出した人から、ここへ

2.1. データの素性を知る (課題 C で配るデータ)

課題 C でみなさんに配るデータファイル (03_sales_data.xlsx または 03_sales_data.csv) について説明します。

実証研究で最も大切なのは、「**自分が扱っているデータが、どこから来て、どういうルールで作られているか**」を正確に把握することです。

列名	意味	補足
firm_id	企業識別コード	各企業に割り当てられた一意の番号
firm_name	企業名	各企業の名称
industry	業種分類	東証業種分類 (食料品、化学、機械、小売業など)
year	決算年度	2024 年度の数値
sales	売上高	単位 : 百万円 (連結決算)
total_assets	総資産	単位 : 百万円
net_income	当期純利益	単位 : 百万円

i 注意点（データの素性）

- **単位は「百万円」です。**例えば `sales` の欄に `10,000` とあれば、1 万円ではなく「100 億円」を意味します。
- **上場企業のみ**を対象としています（非上場の中小企業は含まれていません）。

2.2. 課題 C —— Excel データを R で読み込んで分析する

この講義では、手作業での Excel 操作ではなく、**すべて R を使った再現可能な分析**を行います。実務や研究では、Excel 形式（.xlsx）で配布されたデータを R に読み込んで処理することが日常茶飯事です。

2.2.1. 1. 配布データを R で読み込む

配布されたデータファイルを、R のコードで読み込みます。

```
# --- パターン A: Excel ファイル (.xlsx) を直接読み込む場合 ---
# readxl パッケージを使います
library(readxl)
df <- read_excel("03_sales_data.xlsx")

# --- パターン B: CSV ファイル (.csv) を読み込む場合 ---
# R の基本関数で 1 行で読み込みます
df <- read_csv("03_sales_data.csv")
```

2.2.2. 2. R の基本関数で統計量を計算する

読み込んだデータフレーム `df` の `sales`（売上高）列に対して、次の関数を実行します。

```
# ① 平均値の計算
mean(df$sales)

# ② 中央値の計算
median(df$sales)

# ③ 倍率（平均値 ÷ 中央値）
mean(df$sales) / median(df$sales)

# ④ 四分位数を含む要約統計量を一括表示！
summary(df$sales)
```

💡 生成 AI への相談も歓迎！

もし読み込みやコードの実行でエラーが出たら、エラーメッセージをそのまま生成 AI（ChatGPT や Claude 等）に貼り付けて「このエラーを直す R コードを教えて」と聞いてみてください。AI を活用してトラブルを解決するのも立派なスキルです。

2.2.3. 提出フォームに書くこと（moodle+R）

1. あなたが計算した ①平均値、②中央値、③倍率（平均値 ÷ 中央値）の数値
2. 計算結果を見て気づいたことを 1 行で。
> 「_____が、思っていたより_____だった」の形で書いてください。
3. 今回の合言葉：「かぶとむし」（資料確認用）

2.3. 課題 D —— 次回の「環境構築大会」に向けた準備

第 3 回の授業の後半（最後の 15 分）で、「環境構築大会」を行います！

教室で全員一斉に、自分のノート PC に **R + VS Code + Quarto** をインストールします。第 4 回以降、みなさんの PC が本格的なデータ分析マシンに生まれ変わります。

そのための準備として、次の 2 点だけ確認しておいてください：

1. ノート PC を充電して教室に持参する

2. PC の空きディスク容量が 3GB 以上あるか確認しておく

- Windows : エクスプローラー → 「PC」 → C ドライブの空き容量
- Mac : 画面左上のリンゴマーク → 「この Mac について」 → 「ストレージ」