プレゼミ 第 3 回 予習資料

「平均的な日本企業」とはどんな企業か —— R でデータを分析する

松浦 総一（経営学部）

> ℹ この資料の使い方（目安 40 分）
>
> この資料は、第 3 回の授業に向けた**事前学習資料**です。**2 部構成**になっています。
>
> | 順番 | やること | 目安 |
> |---|---|---|
> | 1 | **第 1 部**（この資料の §1〜§2）を読む | 5 分 |
> | 2 | **予想フォーム B に送信する**（moodle+R／← ここで一度資料を閉じる） | 3 分 |
> | 3 | **第 2 部**（§3〜§5）を読む | 10 分 |
> | 4 | **課題 C**：配布データを R で読み込み、平均・中央値を計算して提出 | 15 分 |
>
> 締切は**授業前日の 23:59** です。

1. 第 1 部：まず、予想してください

1.1. 前回の振り返り —— 指標の裏側を見抜く

第 2 回では、「反証可能性」と「ROE のデュポン分解」を学びました。

- 「ROE が高い＝優れた企業」という常識を疑い、デュポン分解によって**「借金（財務レバレッジ）で無理やり ROE を釣り上げていないか」**を確かめる視点を手に入れました。
- 表面的な数字を鵜呑みにせず、**データの構造を疑うこと**こそが実証分析の第一歩です。

第 3 回では、もっと身近で、しかし誰もが日常的に騙されている**「平均」という言葉の罠**に切り込みます。

1.2. 予想してください（3 分・ここで一度閉じる）

ニュースでよく「上場企業の平均給与は〇〇万円」「日本企業の平均売上高は〇〇億円」という報道を目にします。

では、実際に日本の上場企業の**売上高**を集計したとき、**「平均値」と「中央値」**はどのような関係になると思いますか？

> 💡 言葉の定義の確認
>
> - **平均値（Mean）**：全員の売上高を足し算して、会社数で割った値。
> - **中央値（Median）**：会社を売上高の小さい順から大きい順に並べたとき、**ちょうど真ん中（ど真ん中）**に位置する会社の売上高。

! 予想フォームへ（ここから先を読む前に！）

Q. 上場企業の売上高について、「平均値」と「中央値」はどちらが大きいと思いますか？ また、どのくらい差があると思いますか？

① 「平均値」のほうがはるかに大きい（中央値の **2 倍以上**）
② 「平均値」のほうが少し大きい（中央値の **1.1 倍〜2 倍未満**）
③ 「平均値」と「中央値」は**ほぼ同じ**（左右対称の分布）
④ 「中央値」のほうが大きい

理由も 1 行書いて、フォームから送信してください。

提出先：moodle+R の「第 3 回 予想シート B」

- 当たり外れは**成績に一切使いません**。提出したかどうかだけを見ます。
- **先を読んでから答えると、損をします。** この予想の価値は「習う前のあなたの直感」が記録に残ることにあります。授業は、みなさんの予想の集計を映すところから始まります。

2. 第 2 部：予想を出した人から、ここへ

2.1. データの素性を知る（課題 C で配るデータ）

課題 C でみなさんに配るデータファイル（`03_sales_data.xlsx` または `03_sales_data.csv`）について説明します。 データは、Moodle+R で共有します。 任意のフォルダに上記の Excel データや CSV データを保存し、 Positoron でそのフォルダを開き、作業ディレクトリとしてください。 この文章の意味が分からない場合は、生成 AI に聞いてみて下さい。

実証研究で最も大切なのは、**「自分が扱っているデータが、どこから来て、どういうルールで作られているか」**を正確に把握することです。

列名	意味	補足
`firm_id`	企業識別コード	各企業に割り当てられた一意の番号
`firm_name`	企業名	各企業の名称
`industry`	業種分類	東証業種分類（食料品、化学、機械、小売業など）
`year`	決算年度	2024 年度の数値
`sales`	**売上高**	**単位：百万円**（連結決算）
`total_assets`	総資産	単位：百万円
`net_income`	当期純利益	単位：百万円

i 注意点（データの素性）

- **単位は「百万円」です。** 例えば `sales` の欄に `10,000` とあれば、1 万円ではなく「100 億円」を意味します。
- **上場企業のみ**を対象としています（非上場の中小企業は含まれていません）。

2.2. 課題 C —— Excel データを R で読み込んで分析する

この講義では、手作業での Excel 操作ではなく、**すべて R を使った再現可能な分析**を行います。 実務や研究では、Excel 形式（`.xlsx`）で配布されたデータを R に読み込んで処理することが日常茶飯事です。

2.2.1. 1. 配布データを R で読み込む

配布されたデータファイルが、Positoron で開いたフォルダの中に保存されていれば、以下のいずれかの R のコードを実行するだけでファイルを読み込めます。

```
# --- パターン A: Excel ファイル（.xlsx）を直接読み込む場合 ---
# readxl パッケージを使います
library(readxl)
df <- read_excel("03_sales_data.xlsx")

# --- パターン B: CSV ファイル（.csv）を読み込む場合 ---
# R の基本関数で 1 行で読み込めます
df <- read.csv("03_sales_data.csv")
```

2.2.2. 2. R の基本関数で統計量を計算する

読み込んだデータフレーム `df` の `sales`（売上高）列に対して、次の関数を実行します。

```
# ① 平均値の計算
mean(df$sales)

# ② 中央値の計算
median(df$sales)

# ③ 倍率（平均値 ÷ 中央値）
mean(df$sales) / median(df$sales)

# ④ 四分位数を含む要約統計量を一括表示！
summary(df$sales)
```

> 生成 AI への相談も歓迎！
>
> もし読み込みやコードの実行でエラーが出たら、エラーメッセージをそのまま生成 AI（ChatGPT や Claude 等）に貼り付けて「このエラーを直す R コードを教えて」と聞いてみてください。AI を活用してトラブルを解決するのも立派なスキルです。

2.2.3. 提出フォームに書くこと（moodle+R）

1. あなたが計算した **①平均値、②中央値、③倍率（平均値 ÷ 中央値）** の数値
2. 計算結果を見て気づいたことを 1 行で。
   > **「＿＿＿＿＿が、思っていたより＿＿＿＿＿だった」** の形で書いてください。